



UNIVERSIDAD NACIONAL DEL ALTIPLANO

CURSO:

Programación Numérica

DOCENTE:

Ing. Torres Cruz Fredi

ESTUDIANTE:

Milena Kely Churata Mamani

TRABAJO_8

**Resumen del artículo: Comparing the
Moore–Penrose Pseudoinverse and Gradient Descent
for Solving Linear Regression Problems: A
Performance Analysis**

Puno, Perú
21 de diciembre de 2025

1. INFORMACIÓN DEL ARTÍCULO

Autor	Alex Adams
Institución	University of Pittsburgh
Fecha	Mayo 29, 2025
Referencia	arXiv:2505.23552v1 [cs.LG]

2. INTRODUCCIÓN Y CONTEXTO

La regresión lineal es fundamental en estadística y machine learning para modelar relaciones lineales entre variables. El objetivo es encontrar parámetros óptimos β que minimicen el error cuadrático (OLS - Ordinary Least Squares).

Existen dos enfoques principales:

- **Pseudoinversa de Moore-Penrose:** Solución analítica directa mediante operaciones matriciales
- **Gradiente Descendente:** Método iterativo que refina la solución paso a paso

Pregunta central del artículo: ¿Bajo qué condiciones específicas cada método ofrece mejor rendimiento en términos de tiempo, estabilidad y precisión?

3. FUNDAMENTOS TEÓRICOS

3.1. Formulación del Problema

Dado $\mathbf{X} \in R^{n \times d}$ (matriz de características) y $\mathbf{y} \in R^n$ (vector de respuestas), se busca:

$$\hat{\beta} = \arg \min_{\beta \in R^d} \|\mathbf{X}\beta - \mathbf{y}\|_2^2 = \arg \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{X}_i\beta)^2 \quad (1)$$

3.2. Pseudoinversa de Moore-Penrose

Solución exacta mediante:

$$\hat{\beta}_{pinv} = \mathbf{X}^+\mathbf{y} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y} \quad (2)$$

Propiedades:

- Complejidad: $O(nd^2 + d^3)$ usando SVD
- Solución exacta y directa
- Numéricamente robusta vía SVD

3.3. Gradiente Descendente


Actualización iterativa:

$$\beta^{(t+1)} = \beta^{(t)} - \alpha \cdot 2\mathbf{X}^T(\mathbf{X}\beta^{(t)} - \mathbf{y}) \quad (3)$$

donde α es la tasa de aprendizaje.

Propiedades:

- Complejidad por iteración: $O(nd)$
- Complejidad total: $O(k \cdot nd)$ con k iteraciones
- Sensible a α y condicionamiento



4. METODOLOGÍA

4.1. Experimentos con Datos Sintéticos

Se controlaron tres parámetros:


- **Tamaño de muestra** (n): 1000, 5000
- **Dimensionalidad** (d): 10, 50
- **Factor de condicionamiento**: 0.001 (mal condicionado) y 1.0 (bien condicionado)

4.2. Datasets Reales

- California Housing: $n = 20,640$, $d = 8$
- UCI Diabetes: $n = 442$, $d = 10$

4.3. Métricas

- Tiempo de ejecución (segundos)
- MSE: $\frac{1}{n} \|\mathbf{X}\hat{\beta} - \mathbf{y}\|_2^2$
- Iteraciones hasta convergencia (GD)



5. RESULTADOS PRINCIPALES

5.1. Tabla Comparativa de Resultados

Cuadro 1: Resultados experimentales en datos sintéticos

n	d	cond	t_{pinv} (s)	t_{gd} (s)	Error _{gd}
1000	10	1.000	0.00067	0.10293	0.00994
1000	10	0.001	0.00056	0.17713	7.63094
1000	50	1.000	0.00842	0.18450	0.00928
1000	50	0.001	0.00710	0.31250	57.43222
5000	10	1.000	0.00150	0.20027	0.00997
5000	50	1.000	0.01575	3.63456	0.01014

Observaciones clave:

1. Pseudoinversa es **100-300x más rápida** (milisegundos vs segundos)
2. Con datos bien condicionados: ambos logran la misma precisión
3. Con datos mal condicionados: GD **falla completamente** (error > 50)
4. Pseudoinversa mantiene estabilidad independiente del condicionamiento

5.2. Análisis de Eficiencia


5.2.1. Efecto de Dimensionalidad (d)

Pseudoinversa:

- Para $d \leq 50$: extremadamente rápida ($< 0,02$ s)
- Escala como $O(nd^2 + d^3)$

Gradiente Descendente:

- Tiempo por iteración: $O(nd)$
- Mayor d puede requerir más iteraciones




5.2.2. Efecto de Tamaño de Muestra (n)

Pseudoinversa:

- Incremento moderado con n
- Componente $O(nd^2)$ domina cuando $n > d$

Gradiente Descendente Batch:

- Costo crece linealmente con n por iteración
- Para $n \gg 10^6$: SGD más escalable




5.3. Precisión y Estabilidad Numérica

Cuadro 2: Error cuadrático medio según condicionamiento

d	cond	MSE_{pinv}	MSE_{gd}
10	1.000	0.00995	0.00995
10	0.001	0.00995	13.02570
50	1.000	0.00971	0.00971
50	0.001	0.00971	55.15268

Conclusión: La pseudoinversa (vía SVD) es robusta; el GD falla con mal condicionamiento.



5.4. Sensibilidad al Condicionamiento

El número de condición $\kappa(\mathbf{X}^T \mathbf{X})$ es crítico:

- **Bien condicionado** (κ pequeño): Superficie esférica $\rightarrow$ convergencia rápida
- **Mal condicionado** (κ grande): Superficie alargada tipo "valle" $\rightarrow$ convergencia extremadamente lenta

La pseudoinversa es robusta a este factor; el GD es altamente sensible.

6. CONCLUSIONES Y RECOMENDACIONES

6.1. Guía Práctica de Selección

Cuadro 3: Recomendaciones según características del problema

Escenario	Método	Razón
n, d moderados	Pseudoinversa	Rápido, exacto, robusto
$n > 10^6$ muy grande	SGD/Mini-batch	Escalabilidad
Datos mal condicionados	Pseudoinversa	Numéricamente estable
Memoria limitada	Iterativo	Menor uso de memoria
$d \gg n$	Iterativo	Evita d^3

6.2. Hallazgos Principales

1. **Velocidad:** Pseudoinversa es órdenes de magnitud más rápida para problemas moderados
2. **Robustez:** Pseudoinversa mantiene precisión con cualquier condicionamiento
3. **Escalabilidad:** Para datasets masivos, variantes estocásticas (SGD) son necesarias
4. **Preprocesamiento:** GD requiere normalización obligatoria de características

6.3. Técnicas de Mejora para Gradiente Descendente

- **Normalización:** Estandarizar características para mejorar condicionamiento
- **Regularización:** Ridge regression mejora estabilidad
- **Métodos adaptativos:** Adam, RMSprop ajustan tasa de aprendizaje
- **Precondicionamiento:** Transformar problema para reducir κ

7. APLICACIONES Y TRABAJO FUTURO

7.1. Direcciones Futuras Sugeridas

1. Comparar con métodos regularizados (Ridge, LASSO, Elastic Net)
2. Evaluar optimizadores avanzados (Adam, RMSprop, L-BFGS)
3. Técnicas de preconditionamiento y whitening
4. Enfoques híbridos: pseudoinversa + GD
5. Aproximaciones aleatorias (sketching) para matrices grandes

7.2. Implicaciones para Programación Numérica

Este estudio ilustra trade-offs fundamentales en métodos numéricos:

- **Exactitud vs Aproximación:** Soluciones directas vs iterativas
- **Complejidad vs Escalabilidad:** Costo total vs costo por iteración
- **Robustez vs Eficiencia:** Estabilidad numérica vs velocidad

Estos principios se extienden a optimización general y álgebra lineal numérica.

8. REFLEXIÓN FINAL

El artículo proporciona una comparación rigurosa que demuestra que no existe un "mejor método universal". La elección depende del contexto:

- Para aplicaciones típicas de ciencia de datos con datasets moderados: **pseudoinversa**
- Para deep learning con millones de parámetros: **gradiente descendente (SGD/Adam)**
- Para datos mal condicionados: siempre considerar **regularización o pseudoinversa**

La clave está en comprender las características del problema y las propiedades de cada método para tomar decisiones informadas.