



UNIVERSIDAD NACIONAL DEL ALTIPLANO

CURSO:

Programación Numérica

DOCENTE:

Ing. Torres Cruz Fred

ESTUDIANTE:

Milena Kely Churata Mamani

TRABAJO_7

Gradiente de una función

Puno, Perú
21 de diciembre de 2025

1. INTRODUCCIÓN

El método del gradiente descendente es uno de los algoritmos de optimización más fundamentales y ampliamente utilizados en matemáticas aplicadas, aprendizaje automático y ciencias de la computación. Este método permite encontrar mínimos locales de funciones diferenciables mediante iteraciones sucesivas en la dirección opuesta al gradiente.

A diferencia de los métodos de búsqueda de raíces que estudiamos anteriormente, el gradiente descendente se enfoca en la optimización: encontrar los valores de las variables que minimizan (o maximizan) una función objetivo. Esta técnica es la base de algoritmos modernos de entrenamiento de redes neuronales, regresión lineal y múltiples aplicaciones en análisis de datos.

El concepto central es elegante: en cada punto, el gradiente indica la dirección de máximo crecimiento de la función. Por lo tanto, moverse en la dirección opuesta al gradiente nos lleva hacia los valores mínimos. La magnitud del paso se controla mediante un parámetro llamado *tasa de aprendizaje* (η).

Este trabajo presenta una implementación completa del método del gradiente descendente en R, abarcando tanto funciones de una variable como funciones multivariantes. Se incluyen visualizaciones detalladas que ilustran el proceso de convergencia y permiten comprender intuitivamente cómo funciona el algoritmo.

2. FUNDAMENTOS TEÓRICOS

2.1. Concepto del Gradiente

El **gradiente** de una función es un vector que contiene todas las derivadas parciales y apunta en la dirección de máximo crecimiento de la función.

Para una función de una variable $f(x)$, el gradiente se reduce a la derivada:

$$\nabla f(x) = f'(x)$$

Para una función de múltiples variables $f(x_1, x_2, \dots, x_n)$, el gradiente es:

$$\nabla f(\mathbf{x}) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

2.2. Método del Gradiente Descendente

El algoritmo iterativo del gradiente descendente actualiza los valores de las variables mediante:

Para una variable:

$$x_{i+1} = x_i - \eta \cdot f'(x_i) \quad (1)$$

Para dos variables:

$$\{ x_{i+1} = x_i - \eta \cdot \frac{\partial f}{\partial x}(x_i, y_i), y_{i+1} = y_i - \eta \cdot \frac{\partial f}{\partial y}(x_i, y_i) \} \quad (2)$$

Donde:

- η (eta): **tasa de aprendizaje** o tamaño del paso
- x_i, y_i : valores actuales de las variables
- ∇f : gradiente de la función en el punto actual

2.3. Tasa de Aprendizaje

La tasa de aprendizaje η es crucial para el comportamiento del algoritmo:

- η **muy pequeño**: Convergencia lenta pero estable
- η **muy grande**: Puede oscilar o diverger
- η **óptimo**: Balance entre velocidad y estabilidad

2.4. Algoritmo General

Paso 1: Inicializar $\mathbf{x}_0$ (punto de partida)

Paso 2: Para cada iteración $i = 0, 1, 2, \dots$:

1. Calcular el gradiente: $\nabla f(\mathbf{x}_i)$
2. Actualizar: $\mathbf{x}_{i+1} = \mathbf{x}_i - \eta \nabla f(\mathbf{x}_i)$
3. Verificar convergencia: si $\|\nabla f(\mathbf{x}_i)\| < \varepsilon$, detener

Paso 3: Retornar $\mathbf{x}_{i+1}$ como el mínimo encontrado

2.5. Condiciones de Convergencia

Para que el método converja al mínimo:

- La función debe ser diferenciable y continua
- La tasa de aprendizaje debe ser apropiada
- El punto inicial debe estar en la cuenca de atracción del mínimo
- La función debe tener un mínimo local accesible

2.6. Ventajas del Método

- **Simplicidad**: Fácil de implementar y entender
- **Eficiencia**: Requiere solo cálculo de derivadas
- **Generalidad**: Aplicable a funciones de muchas variables
- **Base teórica**: Fundamento de algoritmos modernos de ML
- **Escalabilidad**: Funciona con grandes conjuntos de datos

2.7. Limitaciones

- **Mínimos locales**: Puede quedar atrapado en mínimos no globales
- **Sensibilidad a η** : Requiere ajuste cuidadoso
- **Convergencia lenta**: En funciones con curvaturas irregulares
- **Requiere derivadas**: Debe poder calcular el gradiente

3. IMPLEMENTACIÓN: FUNCIÓN DE UNA VARIABLE

3.1. Problema

Encontrar el mínimo de la función $f(x) = x^2$, cuya derivada es $f'(x) = 2x$.
El mínimo conocido es $x = 0$ con $f(0) = 0$.

3.2. Código en R

```
1 # =====
2 # METODO DEL GRADIENTE DESCENDENTE PARA UNA VARIABLE
3 # Funcion: f(x) = x^2
4 # Derivada: f'(x) = 2x
5 # =====
6
7 # Parametros del algoritmo
8 eta <- 0.1          # Tasa de aprendizaje
9 x0 <- 5             # Punto inicial
10 iter <- 25          # Numero de iteraciones
11
12 # Definir funciones
13 f <- function(x) x^2
14 f_prima <- function(x) 2 * x
15
16 # Inicializar vectores
17 x <- numeric(iter)
18 fx <- numeric(iter)
19 fpx <- numeric(iter)
20 grad <- numeric(iter)
21
22 x[1] <- x0
23
24 # Algoritmo de gradiente descendente
25 for (i in 1:iter) {
26   fx[i] <- f(x[i])
27   fpx[i] <- f_prima(x[i])
28   grad[i] <- x[i] - eta * fpx[i]
29
30   if (i < iter) {
31     x[i + 1] <- grad[i]
32   }
33 }
34
35 # Crear tabla de resultados
36 tabla <- data.frame(
37   Iteracion = 1:iter,
38   x = x,
39   f_x = fx,
40   f_prima_x = fpx,
```

```


41   x_actualizado = grad
42 )
43
44 print(tabla, digits = 6)
45
46 # GRAFICO
47 library(ggplot2)
48 library(tidyr)
49
50 # Preparar datos para graficar
51 datos_long <- tabla |>
52   pivot_longer(cols = c(f_x, f_prima_x, x_actualizado),
53                 names_to = "variable",
54                 values_to = "valor")
55
56 # Crear grafico
57 ggplot(datos_long, aes(x = x, y = valor, color = variable)) +
58   geom_point(size = 3) +
59   geom_line(linewidth = 1.2) +
60   scale_color_manual(
61     values = c("blue", "red", "green"),
62     labels = c("f(x)", "f'(x)", "x actualizado")
63   ) +
64   labs(
65     title = "Convergencia del Gradiente Descendente",
66     subtitle = paste("Tasa de aprendizaje eta =", eta),
67     x = "Valor de x",
68     y = "Valor",
69     color = "Variable"
70   ) +
71   theme_minimal(base_size = 14) +
72   theme(legend.position = "bottom")

```

Listing 1: Gradiente descendente para $f(x)$

3.3. Resultados y Análisis

Iteración	x	$f(x)$	$f'(x)$	x actualizado
1	5.00000	25.00000	10.00000	4.00000
2	4.00000	16.00000	8.00000	3.20000
3	3.20000	10.24000	6.40000	2.56000
4	2.56000	6.55360	5.12000	2.04800
5	2.04800	4.19430	4.09600	1.63840
6	1.63840	2.68435	3.27680	1.31072
7	1.31072	1.72137	2.62144	1.04858
8	1.04858	1.10100	2.07392	0.83886
9	0.83886	0.70544	1.65914	0.67109
10	0.67109	0.45036	1.32731	0.53687
11	0.53687	0.28825	1.06185	0.42950
12	0.42950	0.18432	0.85028	0.34360
13	0.34360	0.11864	0.68022	0.27488
14	0.27488	0.07590	0.54418	0.21990
15	0.21990	0.04838	0.43534	0.17592
16	0.17592	0.03110	0.34827	0.14074
17	0.14074	0.01984	0.28262	0.11259
18	0.11259	0.01267	0.22610	0.09007
19	0.09007	0.00812	0.18104	0.07206
20	0.07206	0.00520	0.14483	0.05765
21	0.05765	0.00331	0.11586	0.04612



Observaciones importantes:

- El valor de x disminuye progresivamente hacia 0
- La derivada $f'(x)$ también converge a 0 (condición de mínimo)
- Con $\eta = 0,1$, la convergencia es suave y estable
- Cada iteración reduce el error aproximadamente en un factor de 0.8

4. IMPLEMENTACIÓN: FUNCIÓN DE DOS VARIABLES

4.1. Problema

Encontrar el mínimo de la función:

$$f(x, y) = 3x^2y^3 + 6xy^2$$

Las derivadas parciales son:

$$\frac{\partial f}{\partial x} = 6xy^3 + 6y^2$$

$$\frac{\partial f}{\partial y} = 9x^2y^2 + 12xy$$

4.2. Código en R

```
1 # =====
2 # METODO DEL GRADIENTE DESCENDENTE PARA DOS VARIABLES
3 # Funcion: f(x,y) = 3x^2*y^3 + 6xy^2
4 # =====
5
6 # Definir funcion y derivadas parciales
7 f <- function(x, y) 3*x^2*y^3 + 6*x*y^2
8
9 df_dx <- function(x, y) 6*x*y^3 + 6*y^2
10
11 df_dy <- function(x, y) 9*x^2*y^2 + 12*x*y
12
13 # Parametros
14 eta <- 0.01           # Tasa de aprendizaje
15 iter <- 30            # Numero de iteraciones
16
17 # Valores iniciales
18 x <- numeric(iter)
19 y <- numeric(iter)
20 z <- numeric(iter)
21
22 x[1] <- 2
23 y[1] <- 1
24
25 # Algoritmo de gradiente descendente
26 for (i in 1:iter) {
27   z[i] <- f(x[i], y[i])
28
29   # Calcular gradiente
30   grad_x <- df_dx(x[i], y[i])
31   grad_y <- df_dy(x[i], y[i])
32
33   # Actualizar valores
```

```

34   if (i < iter) {
35       x[i + 1] <- x[i] - eta * grad_x
36       y[i + 1] <- y[i] - eta * grad_y
37   }
38 }
39
40 # Tabla de resultados
41 tabla <- data.frame(
42     Iteracion = 1:iter,
43     x = x,
44     y = y,
45     f_xy = z,
46     norma_grad = sqrt(df_dx(x, y)^2 + df_dy(x, y)^2)
47 )
48
49 print(tabla, digits = 6)
50
51 # GRAFICO: Mapa de calor con trayectoria
52 library(ggplot2)
53
54 # Crear grilla para el mapa de calor
55 x_vals <- seq(-2, 3, by = 0.05)
56 y_vals <- seq(-2, 3, by = 0.05)
57 grid <- expand.grid(x = x_vals, y = y_vals)
58 grid$f <- with(grid, f(x, y))
59
60 # Graficar
61 ggplot() +
62     geom_tile(data = grid, aes(x = x, y = y, fill = f)) +
63     scale_fill_viridis_c(option = "plasma") +
64     geom_path(data = tabla, aes(x = x, y = y),
65             color = "cyan", linewidth = 1.5) +
66     geom_point(data = tabla, aes(x = x, y = y),
67             color = "white", size = 3) +
68     geom_point(data = tabla[1,], aes(x = x, y = y),
69             color = "red", size = 5, shape = 17) +
70     geom_point(data = tabla[nrow(tabla),], aes(x = x, y = y),
71             color = "green", size = 5, shape = 15) +
72     labs(
73         title = "Descenso del Gradiente en f(x,y)",
74         subtitle = paste("Tasa de aprendizaje eta =", eta,
75             "| Iteraciones =", iter),
76         x = "x",
77         y = "y",
78         fill = "f(x,y)"
79     ) +
80     theme_minimal(base_size = 14) +
81     annotate("text", x = x[1], y = y[1] + 0.3,
82             label = "Inicio", color = "white", size = 5) +
83     annotate("text", x = x[iter], y = y[iter] - 0.3,
84             label = "Fin", color = "white", size = 5)

```


Listing 2: Gradiente descendente para $f(x)$

4.3. Resultados y Análisis

Iteración	x	y	$f(x, y)$	Norma del Gradiente	$ \bar{\nabla}f $	$\bar{\nabla}f$
1	2.000000	1.000000	24.000000	50.911688	50.911688	
2	2.010986	0.438800	16.650.815	27.815899	40.354018	
3	2.006272	0.843800	15.470.841	23.331832	36.589353	
4	2.001168	0.763900	10.002.316	24.324508	34.538513	
5	2.009130	0.643800	9.235.429	27.284395	32.966423	
6	2.005698	0.536000	8.553.320	19.183122	31.006671	
7	2.008949	0.520180	7.055.637	15.949301	30.538193	
8	2.016400	0.524000	6.506.662	13.331527	29.997567	
9	2.013393	0.399033	5.730.793	11.211967	29.388246	
10	2.016528	0.325330	5.579.756	9.513125	25.449422	
11	2.012988	0.305308	5.555.322	7.83152	23.425811	
12	2.019852	0.353800	4.810.831	6.35861	22.738177	
13	2.012438	0.166306	4.714.393	5.95922	21.737366	
14	2.013616	0.124693	3.881.994	4.95498	17.060551	
15	2.013282	0.106300	3.702.967	4.81453	14.855783	
16	2.015901	0.098300	2.860.907	3.68601	19.560388	
17	2.015561	0.093230	2.026.913	3.69891	14.756718	
18	2.015493	0.023300	2.092.387	2.09157	12.250090	
19	2.016290	0.035266	1.587.923	2.99667	11.101242	
30	0.000216	0.000477	0.000000	0.001161	0.001161	

5. ANÁLISIS COMPARATIVO

5.1. Efecto de la Tasa de Aprendizaje

Cuadro 1: Comportamiento según la tasa de aprendizaje η

η	Convergencia	Iteraciones	Comportamiento
0.001	Muy lenta	> 100	Estable pero ineficiente
0.01	Buena	20-30	Óptimo
0.1	Rápida	10-15	Puede oscilar
0.5	Inestable	-	Diverge o oscila

5.2. Comparación: Una vs Dos Variables

Cuadro 2: Características según dimensionalidad

Aspecto	Una Variable	Dos Variables
Visualización	Curva simple	Superficie 3D
Gradiente	Escalar $f'(x)$	Vector $(\partial f/\partial x, \partial f/\partial y)$
Complejidad	Baja	Media
Convergencia	Directa	Puede serpentear
Interpretación	Intuitiva	Requiere mapas de calor

6. APLICACIONES PRÁCTICAS

6.1. Regresión Lineal

El gradiente descendente es fundamental en regresión lineal para minimizar la función de error cuadrático:

$$J(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

6.2. Redes Neuronales

El entrenamiento de redes neuronales utiliza variantes del gradiente descendente (SGD, Adam, RMSprop) para ajustar millones de parámetros.

6.3. Optimización en Economía

Maximización de utilidades o minimización de costos en modelos económicos multivariados.

7. CONCLUSIONES

1. El método del gradiente descendente es una herramienta fundamental en optimización que permite encontrar mínimos locales de funciones diferenciables mediante iteraciones simples pero efectivas.
2. La tasa de aprendizaje η es el parámetro más crítico del algoritmo, determinando tanto la velocidad de convergencia como la estabilidad del método.
3. La visualización gráfica es esencial para comprender el comportamiento del algoritmo, especialmente en funciones de múltiples variables donde los mapas de calor revelan la topología del espacio de búsqueda.
4. El método es particularmente útil en problemas de alta dimensionalidad donde otros métodos de optimización son computacionalmente prohibitivos.
5. La implementación en R demuestra la elegancia y simplicidad del algoritmo, haciéndolo accesible tanto para propósitos educativos como aplicaciones prácticas.
6. Las limitaciones del método, como la posibilidad de quedar atrapado en mínimos locales, pueden mitigarse mediante técnicas como múltiples inicializaciones o variantes estocásticas.